Predikcija dnevne prodaje u Rossmann prodavnicama

Projekat iz mašinskog učenja

Luka Milutinoivić

Univerzitet u Beogradu Elektrotehnički fakultet

November 13, 2025

1. Uvod
2. Eksplorativna analiza podataka
3. Modelovanje
4. Rezultati
5. Zaključak i dalji pravci

1 Uvod

2 Eksplorativna analiza podataka

3 Modelovanje

4 Rezultati

5 Zaključak i dalji pravci

Uvod

Opis problema: Cilj je da se predvidi prodaja u Rossmann prodavnicama za period od šest nedelja unapred, koristeći skup dostupnih karakteristika koje opisuju poslovanje svake prodavnice.

Korišćena obeležja uključuju:

- promocije (`Promo`, `Promo2`),
- praznike i posebne događaje (`StateHoliday`),
- tip prodavnice i asortiman (`StoreType`, `Assortment`),
- informacije o konkurenciji (`CompetitionOpenSince`),
- vremenske karakteristike (dan, mesec, godina).

1 Uvod

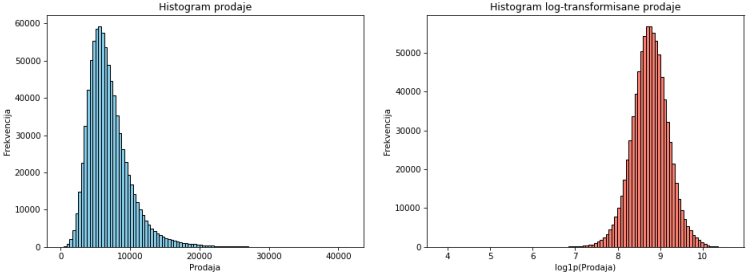
2 Eksplorativna analiza podataka

3 Modelovanje

4 Rezultati

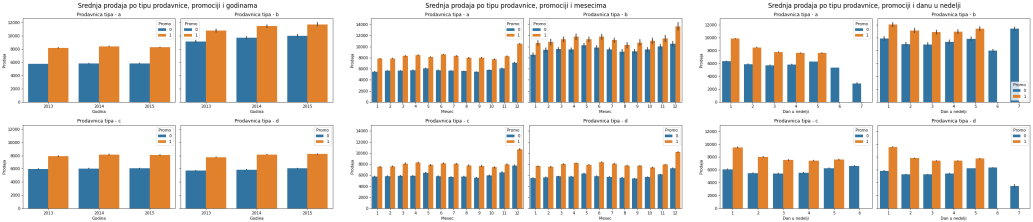
5 Zaključak i dalji pravci

Statistika ciljne promenljive



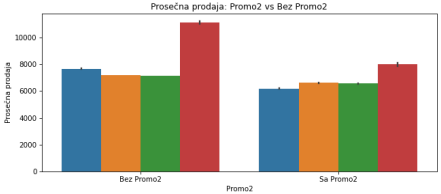
Distribucija prodaje pokazuje izraženu desnu asimetriju, što ukazuje na potrebu za logaritamskom transformacijom ciljne promenljive kako bi se stabilizovala varijansa.

Prodaja u zavisnosti od vremena i promocije



- Vidljiv je sezonski obrazac — porast prodaje u decembru zbog praznika.
- Tokom vikenda, većina prodavnica ima smanjenu prodaju.
- Promocije značajno povećavaju dnevnu prodaju.

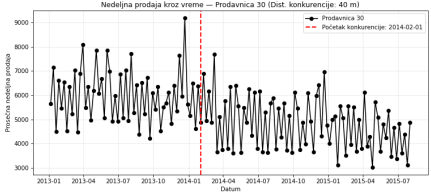
Uticaj programa Promo2

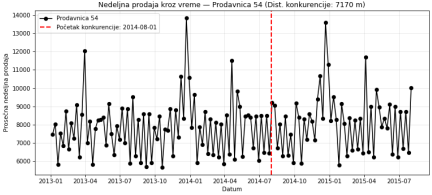




- Prodavnice uključene u dugoročne promocije (Promo2) generalno imaju nižu prodaju.
- Efekat zavisi od tipa prodavnice – najizraženiji kod tipa „a“ i „d“.

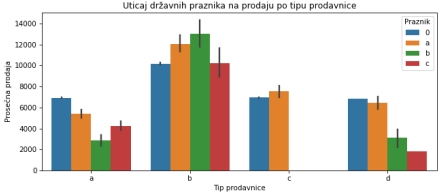
Uticaj udaljenosti konkurencije

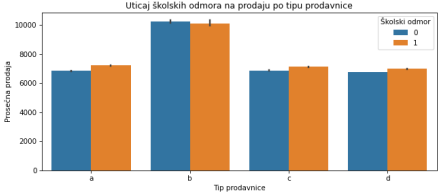




- Prodavnice sa bližom konkurencijom imaju generalno manju prodaju.

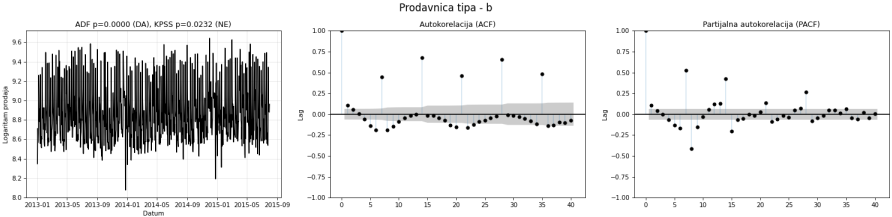
Uticaj praznika i školskih odmora





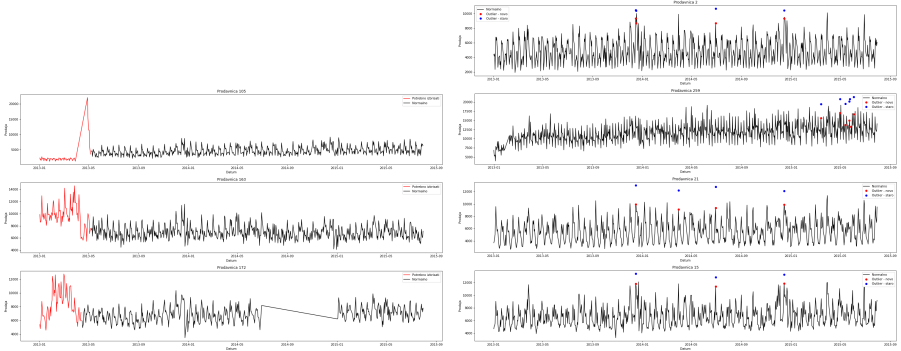
- Tokom državnih praznika prodavnice tipa `b` beleže primetan skok prodaje, dok kod prodavnica tipa `a` i `d` dolazi do blagog pada.
- Tokom školskih odmora uočava se blag porast prodaje.

Provera stacionarnosti vremenske serije



- KPSS test ukazuje na prisustvo slučajnog hoda, što znači da se serija ne može smatrati stacionarnom.
- Na osnovu ACF i PACF analiza primećeno je da situacija značajno varira u zavisnosti od tipa prodavnice, ali se generalno uočava izražena sezonska komponenta na periodu od 7 do 12 dana.
- Kod PACF dijagrama najčešće se ističe autokorelacija sa prethodnim odbirkom ili odbirkom zakašnjenim za 7 dana.

Detekcija i tretman *outlier*-a



- U početnom periodu primećeno je da pojedine prodavnice pokazuju obrasce prodaje koji se ne mogu objasniti dostupnim obeležjima.
- Uočene su ekstremno visoke vrednosti prodaje kod određenih prodavnica, koje mogu negativno uticati na stabilnost i tačnost modela.

1 Uvod

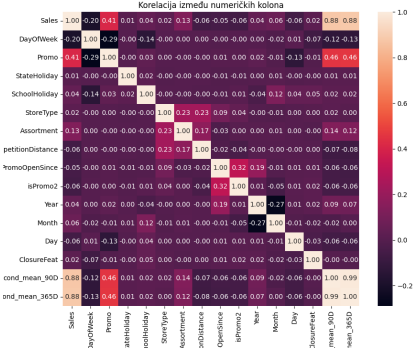
2 Eksplorativna analiza podataka

3 Modelovanje

4 Rezultati

5 Zaključak i dalji pravci

Inženjering karakteristika



- Dodate su sledeće karakteristike:
  - koliko dugo je prisutna konkurencija u okruženju prodavnice,
  - trajanje promotivnih perioda,
  - informacije o prošlim, sadašnjim i budućim praznicima,
  - statističke pokazatelje prodavnice (npr. prosečna prodaja, broj kupaca),
  - **Furijeove komponente** radi hvatanja sezonalnosti.

Modeli

- U radu su korišćena tri pristupa modelovanja:
  - **Konstantan model** – jednostavan bazni koji predviđa prosečnu vrednost prodaje.
  - **Ridge regresija** – linearni model sa regularizacijom, primenjen u tri varijante:
    - *Globalni model* – jedan model za sve prodavnice.
    - *Lokalni model* – poseban model za svaku prodavnicu.
    - *Hibridni model* – kombinacija lokalnog i globalnog pristupa, gde se individualni model svake prodavnice koriguje zajedničkim modelom.
  - **XGBoost** – nelinearni ansambl algoritam zasnovan na gradijentnom *boosting*-u stabala odlučivanja.
    - Model treniran u *globalnom* i *hibridnom* režimu.
    - Omogućava modelovanje nelinearnih odnosa i interakcija između obeležja.

Evaluacija

- Za evaluaciju modela korišćena je metrika **RMSPE** (*Root Mean Square Percentage Error*):

$$RMSPE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(\frac{y_i - \hat{y}_i}{y_i}\right)^2}$$

- RMSPE bolje odražava relativne greške, posebno kod prodavnica sa različitim nivoima prodaje.

1 Uvod

2 Eksplorativna analiza podataka

3 Modelovanje

4 Rezultati

5 Zaključak i dalji pravci

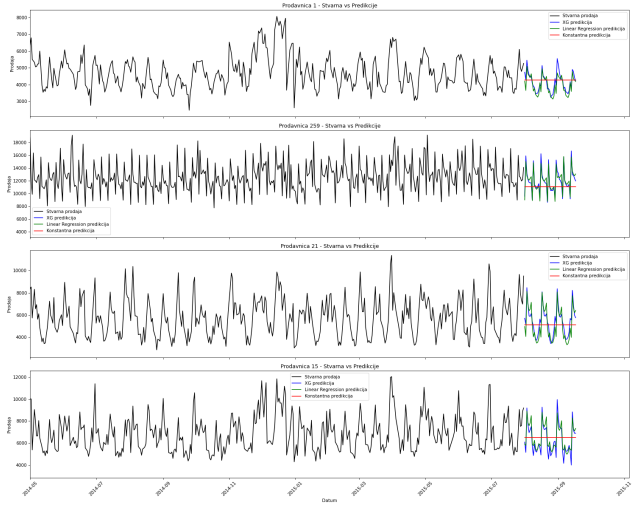
Rezultati modela

Poređenje modela po RMSPE

Model	Tip	Public	Test
Konstantan izlaz	-	0.27098	0.24148
Ridge	Globalno	0.19453	0.19839
	Lokalno	0.11821	0.12940
	Hibridno	0.11765	0.12807
XGBoost	Globalno	0.10385	0.11321
	Hibridno	0.10538	0.11440

- **Bazni model** daje očekivano loše rezultate i služi kao referenca.
- **Ridge regresija** značajno poboljšava performanse, posebno u *lokalnom* i *hibridnom* režimu.
- **XGBoost** ostvaruje najbolje rezultate zahvaljujući mogućnosti modelovanja nelinearnih odnosa i interakcija.

Primer predikcija prodaje po modelima



1 Uvod

2 Eksplorativna analiza podataka

3 Modelovanje

4 Rezultati

5 Zaključak i dalji pravci

Zaključak i dalji pravci

- Prikazana su tri različita pristupa predikcije prodaje Rossmann prodavnica: konstantan izlaz, Ridge regresija i XGBoost.
- Najbolje performanse ostvario je XGBoost zbog sposobnosti modelovanja nelinearnih odnosa i interakcija između promenljivih.
- Poređenje sa Kaggle leaderboard-om: pobednički model na privatnom setu ostvario je RMSPE ≈ 0.10021. Taj model je koristio i meteorološke podatke, što je tehnički bilo dozvoljeno, ali u realnoj primeni nije uvek praktično, jer je teško precizno predvideti vremenske uslove 6 nedelja unapred.
- Preporuke za dalji rad:
  - Primena neuralnih mreža (LSTM, TFT) za vremenske serije.
  - Uvođenje dodatnih spoljnih faktora: vremenska prognoza, Google Trends.